MUTUELLE HORIZON SANTÉ

Bloquer la fraude optique avant de la payer

Un pipeline de données quotidien qui donne chaque matin au gestionnaire anti-fraude la liste des factures à contrôler.

Lucas Stefani · Clément Badalucco · Eliott Monneraie

github.com/emonneraie-blip/Mutuelle_Horizon

Data Engineering & Cloud Infrastructure · Albert School · 5 novembre 2026

Horizon vise à bloquer environ 0,5 M€ de fraude optique par an

112 M€	de fraude à l’assurance santé détectée en France en 2025
53 %	concerne l’optique
≈ 1 M€	de fraude optique non détectée chez Horizon
≈ 0,5 M€	bloqués avant paiement, en arrêtant la moitié

Source : Alfa, rapport annuel (chiffres 2025).
Hypothèse Horizon : 1 % des 200 M€ remboursés sont frauduleux et non détectés.

LE CAS D’USAGE

Chaque matin à 6 h, le gestionnaire sait quelles factures bloquer avant de payer

Jour J

Les opticiens envoient leurs factures

J+1, 06:00

Le pipeline publie la liste des factures à contrôler

J+1, matin

Le gestionnaire bloque et contrôle, ou paie

J+3

Décision « sans décompte Sécu », une fois NOEMIE reçu

Test d’acceptation : au moins 80 % des fraudes repérées, zéro fausse alerte.

AVANT / APRÈS

La fraude se traite avant le paiement, et non plus après coup

Qui	Sans le pipeline	Avec le pipeline
Gestionnaire	contrôle après paiement	chaque matin, les factures à bloquer, avec la règle et le montant
Direction	aucune vue quotidienne	un KPI par lot : alertes, montant bloqué
Paiement	toutes les factures payées	une facture signalée attend le contrôle

Décision à prendre, facture par facture : bloquer et contrôler, ou payer.

Sept règles simples couvrent les fraudes typiques de l’optique

Règle	Ce qui est suspect	Vérifié avec
F1	Équipement renouvelé en moins de 2 ans	historique
F2	Aucun décompte Sécurité sociale	NOEMIE
F3	Montant au-dessus du plafond	CRM, contrat
F4	Opticien inconnu ou fermé	SIRENE
F5	Facture déjà payée à un autre adhérent	historique
F6	Prescripteur absent de l’annuaire	RPPS
F7	Soins après la fin du contrat	CRM

Chaque règle croise la facture avec une source de référence.

Même avec un taux de fraude prudent, le contrôle reste rentable

Fraude non détectée chez Horizon	0,5 %	1 %	2 %
Fraude optique non détectée	0,53 M€	1,06 M€	2,12 M€
Bloquée avant paiement (la moitié)	≈ 0,27 M€	≈ 0,53 M€	≈ 1,06 M€

Charge : ≈ 9 alertes par jour, à 10 min chacune, soit ≈ 1 h 30 de contrôle

Calcul : ≈ 100 $ par an, hors compute pool et temps des gestionnaires

L'ARCHITECTURE · INGEST → TRANSFORM → CONSUME

Trois étapes, un outil justifié pour chacune

Ingest			Transform		Consume
5 sources	→ Ingestion	→ BRONZE	→ SILVER	→ GOLD	→ Dashboard
dont 2 réelles	Python, Docker	brut, tracé	nettoyé, NIR haché	7 règles, liste	liste, KPI

Outil	Pourquoi	Écarté
Snowflake	stockage et calcul séparés, payé à la seconde	BigQuery
Python en Docker	une méthode par source, même image partout	Airbyte, dlt
dbt	couches, 31 tests, lineage	SQL en Snowflake Tasks
Airflow	planification, relances, rattrapage, alertes	Snowflake Tasks, Dagster
Terraform, CI	infrastructure reproductible, relue en PR	scripts SQL manuels

Chaque source arrive par la méthode qui lui correspond

Source	Donnée	Méthode	Jamais chargée deux fois
Factures, CSV quotidien	simulée	fichier, PUT + COPY INTO	mémoire de COPY
NOEMIE, JSON quotidien	simulée	fichier semi-structuré	mémoire de COPY
CRM, Postgres	simulée	incrémental + MERGE	clé adhérent
SIRENE, API publique	réelle	API, nouveaux SIRET	SIRET déjà vérifiés
RPPS, open data	réelle	rechargement complet	remplacement total

Les vraies factures de santé sont inaccessibles (secret médical, RGPD art. 9) : formats réels, contenu simulé, fraudes injectées.

INGEST · IDEMPOTENCE

Rejouer un lot ne compte jamais une facture deux fois

```
▶ Log message source details
▶ Pre Execute
   4  [2026-11-03 09:49:48] INFO - Starting docker container from image fraud-ingest:1.0.0
   5  [2026-11-03 09:49:53] INFO - {"ts": "2026-11-03T08:49:53+00:00", "level": "INFO", "job": "load_invoices", "run_id": "scheduled__2026-11-
      03T05:00:00+00:00", "msg": "batch 2026-11-02: 0 file(s), 0 rows loaded (ALREADY_LOADED); rows in file(s): 185"}
▶ Post Execute
```

Airflow, relance de ingest_factures sur le lot du 02/11, déjà chargé.

185

lignes dans le fichier

0

rechargée

Même garantie pour NOEMIE et pour le CRM, rejoué par MERGE sur la clé.

Sur données simulées, toutes les fraudes décidables sont repérées, sans fausse alerte

Contrôle automatique	Résultat
Fraudes décidables retrouvées, 26/10 → 03/11	81 sur 81
F2 encore en attente (décision à J+3)	3
Factures saines signalées à tort	0
Quarantaine au 03/11, avec motif	9 sur 9
Lot NOEMIE du jour absent	rien publié
Tests dbt, à chaque run	31

Réparé ou mis de côté, jamais deviné :

« 1 234,50 € »	→ 1234.50
« 30/02/2026 »	→ quarantaine, date invalide

Le run du jour traite le lot du 04/11, en direct

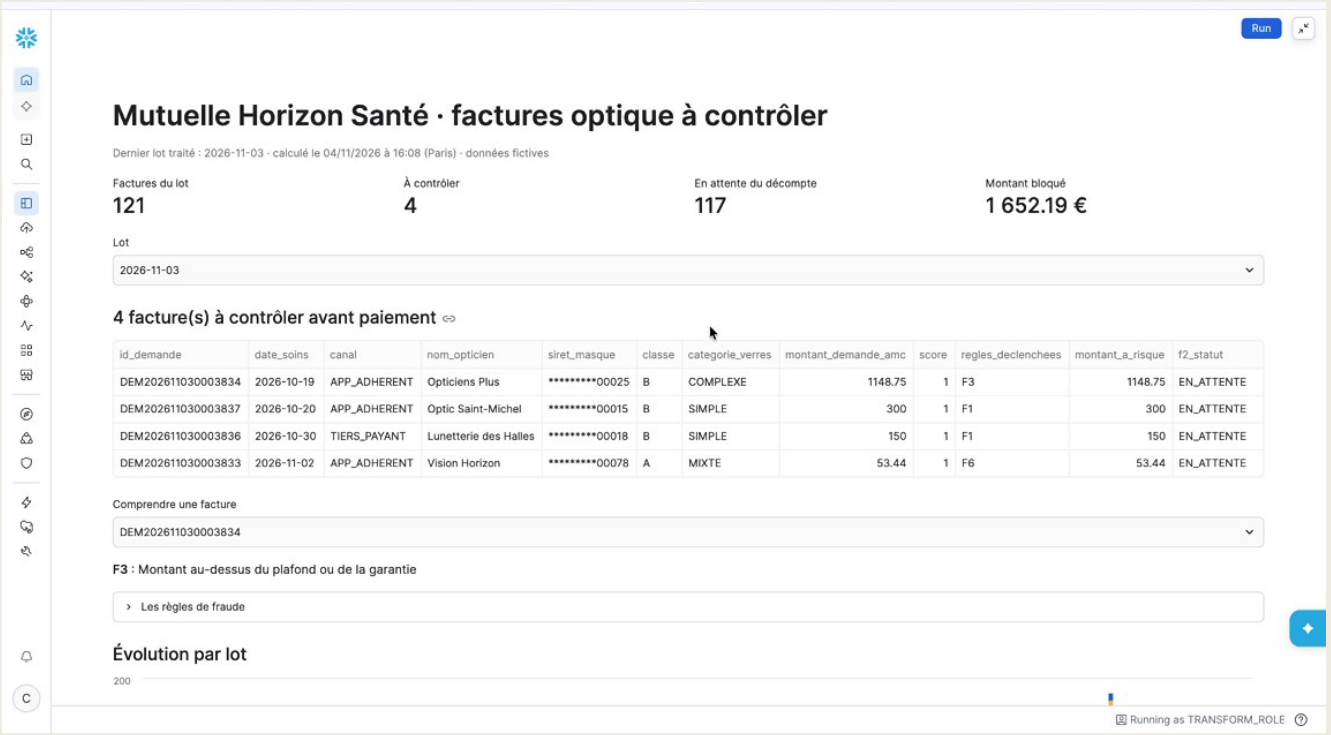
01 Airflow : 6 tâches au vert

02 Relance sans doublon

03 Dashboard : les factures à bloquer

04 Lineage et documentation

05 Accès refusé à un analyste

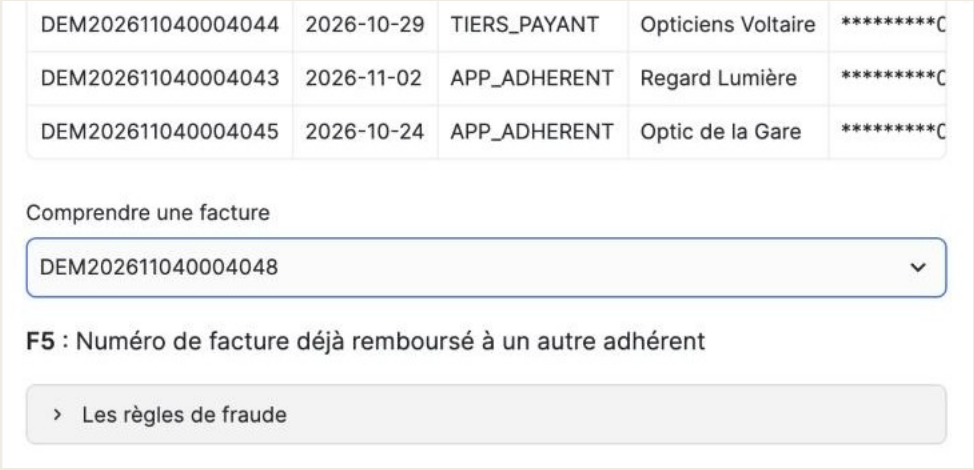


Le dashboard avant le run : lot du 03/11.

CE QUE LA DÉMO A MONTRÉ

En une minute, le lot du 04/11 est chargé, contrôlé et publié

215 → 212	lignes reçues, factures après nettoyage
6	factures à bloquer, 1 678,32 €
0	ligne rechargée à la relance
KPI seul	visible pour un analyste

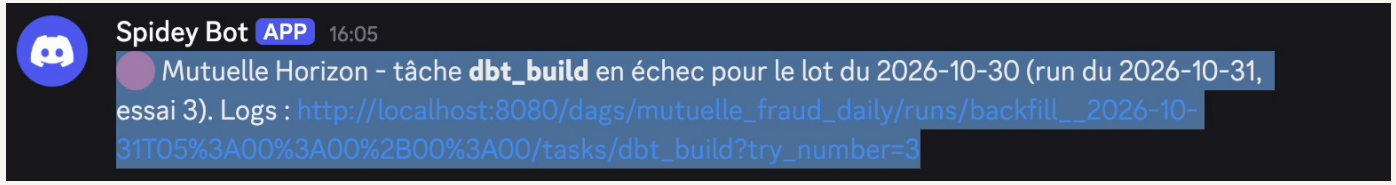


F5 du 04/11 : facture déjà remboursée à un autre adhérent.

RÉSILIENCE

Quand la Sécurité sociale ne livre pas, rien de faux n’est publié

```
 95  [2026-11-03 10:56:27] INFO - 09:56:27  Completed with 1 error, 0 partial successes, and 0 warnings:
 96  [2026-11-03 10:56:27] INFO - 09:56:27
 97  [2026-11-03 10:56:27] INFO - 09:56:27  Failure in test assert_lot_noemie_present (tests/assert_lot_noemie_present.sql)
 98  [2026-11-03 10:56:27] INFO - 09:56:27    Got 1 result, configured to fail if != 0
 99  [2026-11-03 10:56:27] INFO - 09:56:27
100  [2026-11-03 10:56:27] INFO - 09:56:27    compiled code at target/compiled/mutuelle_dbt/tests/assert_lot_noemie_present.sql
101  [2026-11-03 10:56:27] INFO - 09:56:27
102  [2026-11-03 10:56:27] INFO - 09:56:27  Done. PASS=31 WARN=0 ERROR=1 SKIP=15 NO-OP=0 TOTAL=47
103  [2026-11-03 10:56:28] ERROR - Task failed with exception
```



Le test de complétude échoue, puis l’alerte Discord part.

30/10 : fichier absent. Trois essais, liste non publiée, équipe alertée.

31/10 : fichier reçu. Le run repasse au vert, sans intervention.

Chaque donnée a un responsable, une sensibilité et une trace

Pilier	Chez nous	Preuve
Responsable	ingestion pour BRONZE, transformation pour SILVER et GOLD	CODEOWNERS, un README par dossier
Qualité	31 tests dbt, quarantaine avec son motif	docs/contracts.md
Classification	public : SIRENE, RPPS · interne : KPI · santé : NIR, factures	documentée, sans tags Snowflake
Lineage	chaque ligne relie son fichier et son run d’origine	dbt docs, _SOURCE_FILE, _RUN_ID
Minimisation	ni NIR ni nom dans ADHERENTS, NIR haché, SIRET masqué	docs/security.md
Audit	chaque chargement et chaque test laissent une trace	LOAD_AUDIT, DBT_RESULTS, Airflow

SÉCURITÉ ET COÛTS

La sécurité applique ces règles, pour environ 100 $ de calcul par an

Mécanisme	Chez nous
Authentification	clés RSA pour les comptes de service, MFA pour les humains
Autorisation	un rôle par couche, moindre privilège : l’analyste ne voit que le KPI
Protection	NIR haché avec un sel secret, SIRET masqué

≈ 100 $

par an, hors compute pool et temps des gestionnaires

3 entrepôts XSMALL, arrêt après 60 s

Infrastructure Terraform, état sur HCP

Avant la production : valider sur de vraies factures, puis apprendre un score

0,5 M€ par an visés, pour environ 100 $ de calcul.

Risques à maîtriser

- Une fausse alerte bloque un opticien honnête
- Le NIR haché reste une donnée personnelle (RGPD)
- Règles validées sur données simulées seulement

La suite

- Vrais flux NOEMIE et CRM, en continu
- Un score appris sur les contrôles du gestionnaire
- Dentaire et audioprothèses